Prediction probabiliste de la fin d'un orage

Data Battle 2026 — Meteorage

Anticipation intelligente de la levee d'alerte orageuse
pour les aeroports europeens

Equipe : [Nom de l'equipe]

Contexte et problematique

Le probleme

- **Alerte fixe de 30-60 min**
apres le dernier eclair detecte

- **Centaines d'heures perdues**
chaque annee par aeroport

- **Approche conservative**
qui ignore la dynamique de l'orage

Notre solution

- **Modele probabiliste**
qui estime la fin reelle de l'orage

- **Score de confiance [0,1]**
pour chaque eclair CG

- **Levee anticipee de l'alerte**
quand score >= theta

Pipeline global

De la donnee brute a la decision operationnelle

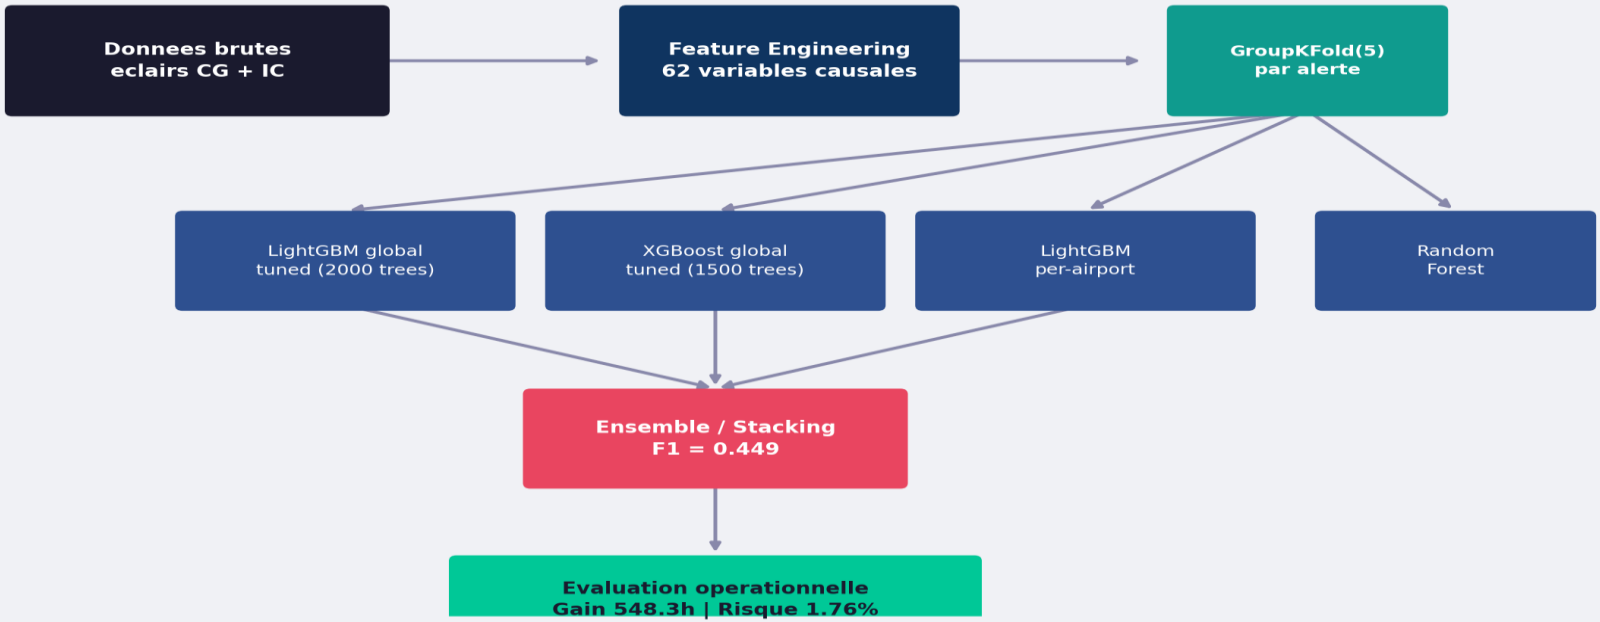

Les donnees

507K
Eclairs train

188K
Eclairs eval

5
Aeroports

4.64%
Positifs (1:20)

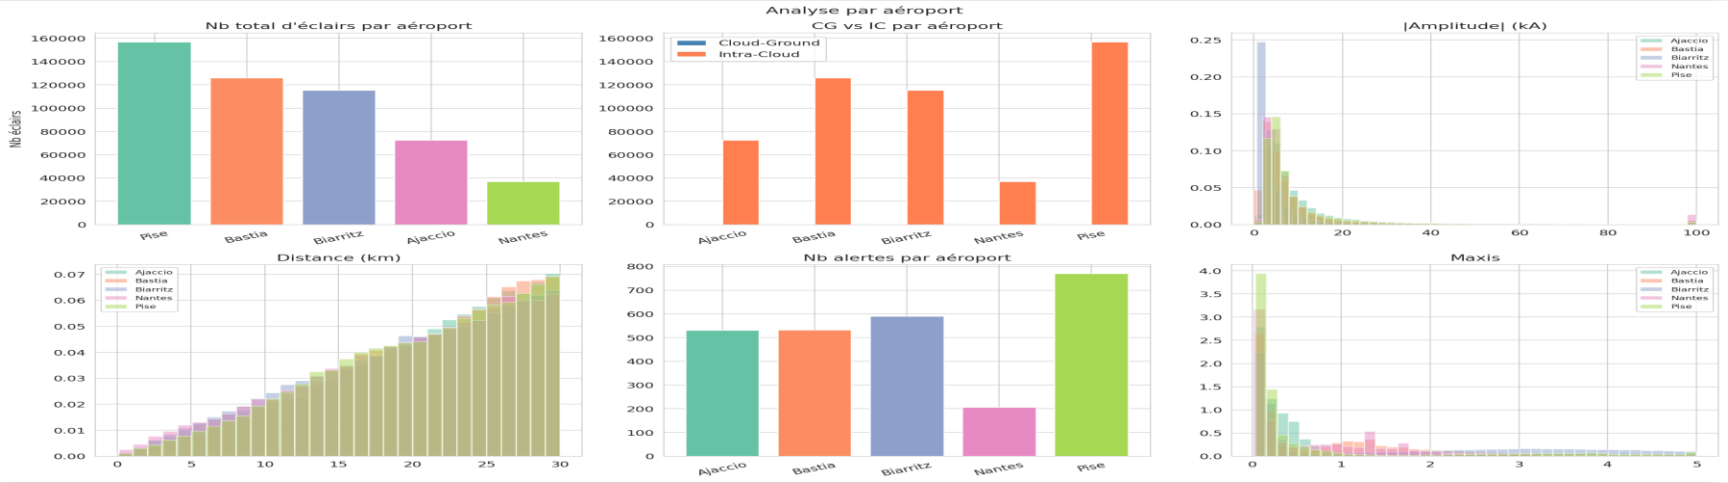

Feature Engineering

62 variables causales — aucune fuite de donnees

Position

rank_cg, t_since_start

Probabilite croissante

Temps inter-eclairs

dt_prev, dt_mean, dt_ema

Espacement = fin

Distance

dist, dist_mean, trend

Orage s'eloigne

Intensite

amp_abs, maxis, trend

Declin energetique

Densite CG

n_cg_2/5/10/15/30min

Ralentissement

Contexte IC

n_ic, ratio_ic_cg

Precurseur de fin

Metadata

month, hour, azimuth

Saisonnalite

Flux de prediction

Pour chaque eclair CG : calcul des features, score, decision

Signaux discriminants

Le dernier eclair CG vs les eclairs precedents

+167% Espacement temporel

+13% Distance a l'aeroport

-81% Densite d'activite

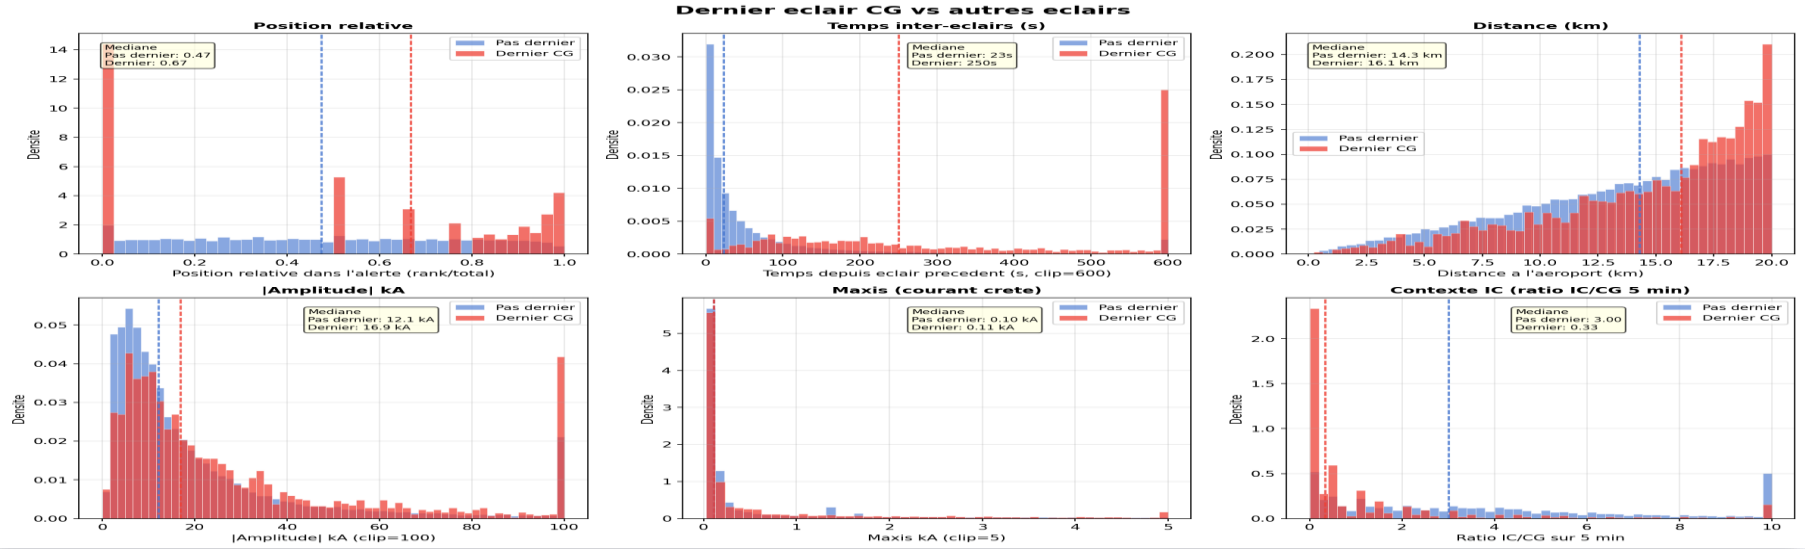

Importance des features

Top 20 features par gain LightGBM — l'azimuth, le maxis et la distance dominent

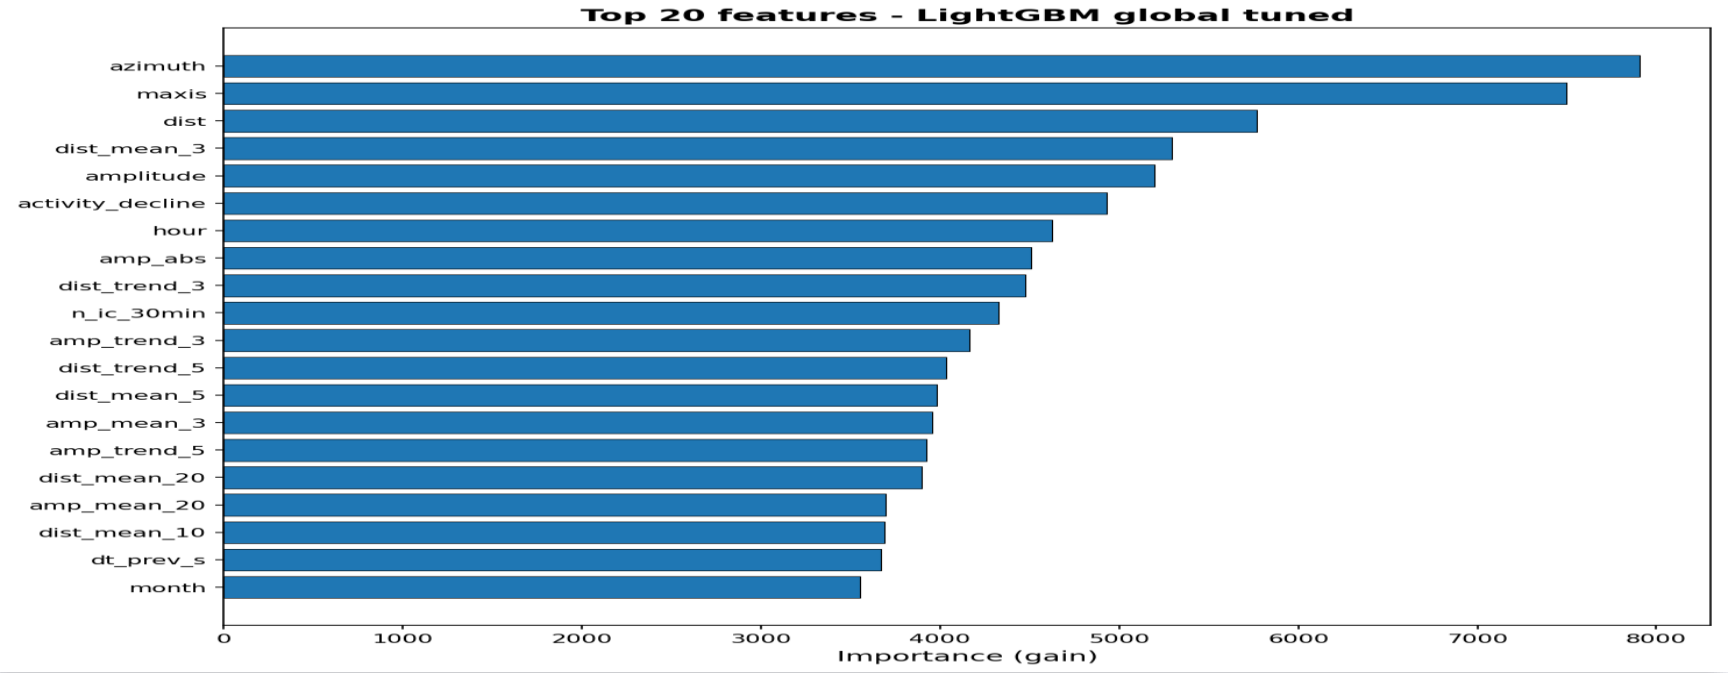

Comparaison des modeles

Modele	AUC-ROC	AUC-PR	F1	MCC
Ensemble (LGB+XGB+per-ap)	0.935	0.416	**0.449**	0.425
XGBoost tuned (1500)	**0.937**	**0.419**	0.448	**0.433**
LightGBM tuned (2000)	0.934	0.409	0.440	0.419
Random Forest balanced	0.935	0.405	0.439	0.417
Logistic Regression	0.917	0.292	0.389	0.369

Desequilibre 4.64% → l'accuracy est inadaptee. AUC-PR et F1 sont les metriques de reference.

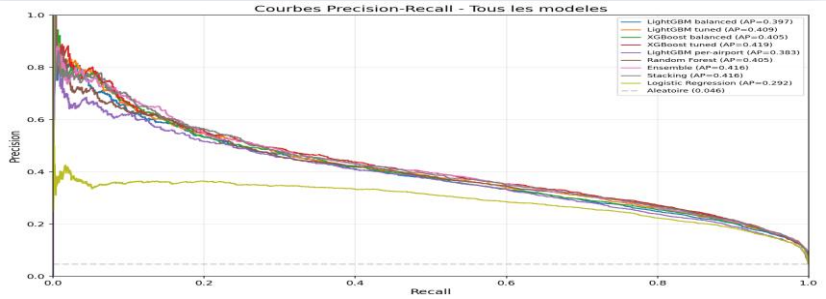

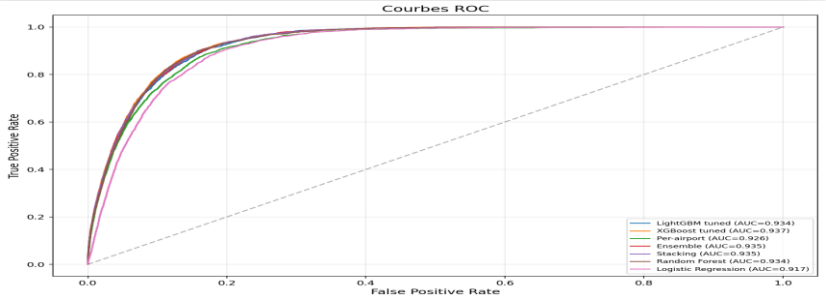

Evaluation operationnelle

548.3h
Gain total
1081 alertes eval

30.4 min
Gain par alerte
vs 0 min baseline

1.76%
Risque
contrainte < 2%

0.85
Seuil theta
XGBoost global

Modele	Theta	Gain (h)	Risque	Gain/alerte
Baseline (30 min)	-	0	0.00%	0 min
LightGBM global	0.90	278.5	1.90%	15.5 min
Ensemble	0.80	404.0	1.79%	22.4 min
XGBoost global	**0.85**	**548.3**	**1.76%**	**30.4 min**
LightGBM per-airport	0.60	573.8	1.88%	31.8 min

Gain vs Risque

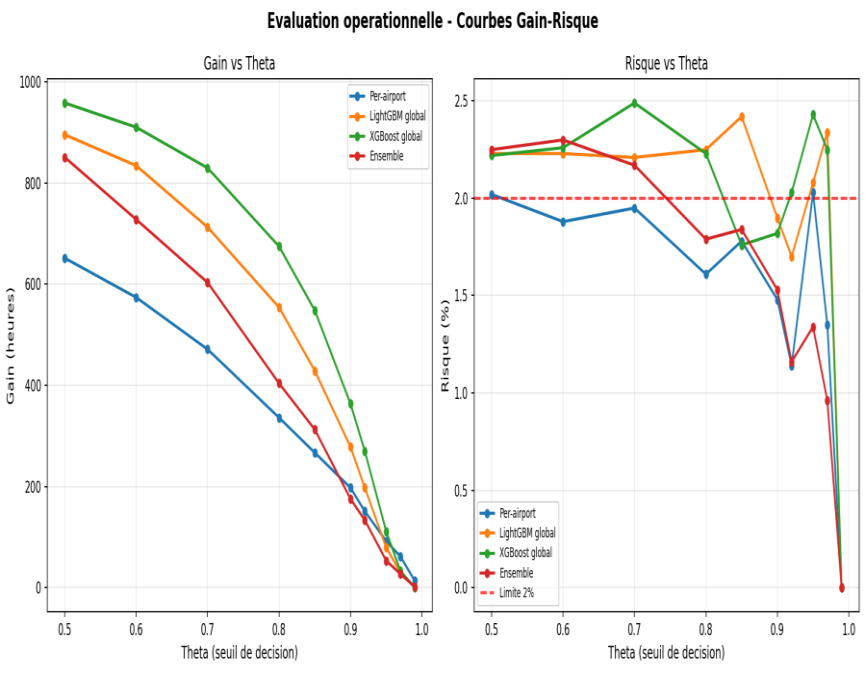

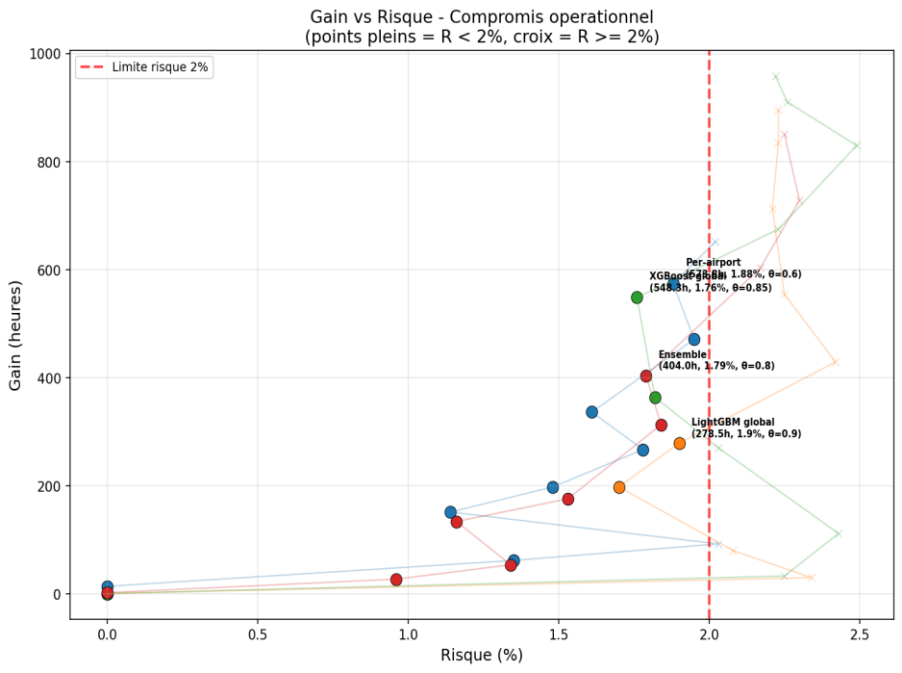

Points pleins = Risque < 2% (zone valide) | Croix = Risque >= 2%

Performances par aeroport

Aeroport	AUC	F1	Theta opt.	Profil meteo
Ajaccio	0.933	0.455	0.248	Convection mediterraneenne
Bastia	0.923	0.395	0.282	Mediterraneen, variabilite moderee
Biarritz	0.924	0.467	0.132	Atlantique, trajectoires O-E
Nantes	0.905	0.426	0.079	Continental, peu d'alertes
Pise	0.931	0.441	0.422	Ligurien, fort ratio IC/CG

Variabilite des seuils (0.079 Nantes vs 0.422 Pise) → justifie les modeles specialises

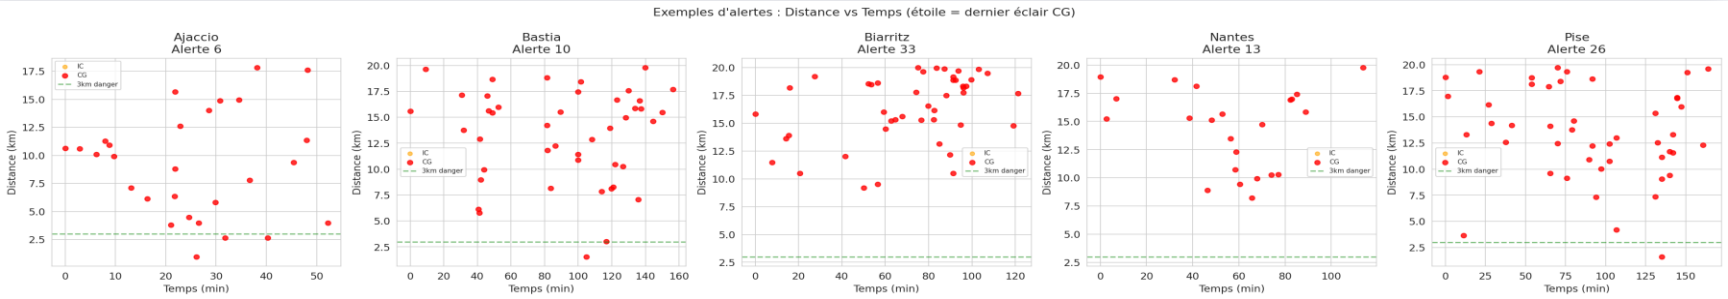

Application Streamlit

databattle-ai-2026.streamlit.app

Page 1

Prediction en temps reel

Selectionner un aeroport et une alerte, ajuster theta, visualiser le score de confiance en 3 panneaux (score, distance, activite CG)

Page 2

Analyse exploratoire

20 figures EDA : distribution par aeroport, saisonnalite, structure des alertes, signaux discriminants, courbes operationnelles

Page 3

Guide d'utilisation

Tableau des seuils par aeroport, interpretation du score, pipeline technique complet et format CSV attendu

Conclusion

548.3 heures de gain operationnel sur 1081 alertes

Risque de 1.76% — contrainte de securite < 2% respectee

30 minutes recuperees par alerte en moyenne

Modeles specialises par aeroport pour capturer les specificites locales

Merci — Questions ?